

台灣癌症登錄資料庫系列研究：從傳統流行病學到深度學習的多維度整合分析——研究成果總論

版本：2026-06-06

涵蓋子計畫：17個（台灣癌症登錄系列12個、CMUH單中心1個、TCGA多體學3個、TCGA-ESCA 1個）

資料來源：台灣癌症登錄資料庫（n=84,161；46部位；2003–2020）、CMUH（n=344）、TCGA-ESCA/BRCA/THCA

摘要

本系列研究以台灣癌症登錄資料庫（n=84,161；46個癌症部位；2003–2020年）為核心，輔以中山醫學大學附設醫院（CMUH）食道癌單中心資料庫（n=344）及TCGA多體學資料集（ESCA、BRCA、THCA），系統性探索台灣特有的致癌暴露模式、共存癌症的生物學機制、遺傳症候群篩查，以及序列深度學習在個人化腫瘤監測中的應用。跨越十七個相互關聯的子計畫，本系列研究識別出台灣癌症共病空間的三個主要致癌軸：（1）上消化呼吸道（UADT）場域致癌效應（由檳榔、菸草、酒精三重暴露驅動）；（2）B型肝炎病毒（HBV）/腸胃道代謝軸（由台灣盛行的HBV感染及代謝症候群共同形塑）；（3）荷爾蒙/婦科軸（以子宮體癌與乳癌的上升趨勢為代表）。深度學習轉換器模型在癌症序列預測中達到 $R@1=0.232$ （為隨機基準的8.6倍），並支援以首發癌症部位為條件的個人化後續監測日曆。本文就各子計畫之研究設計、核心發現、方法學創新及臨床轉化意涵進行系統性整合陳述。

一、研究背景與整體架構

台灣癌症登錄資料庫是全球少數同時涵蓋大規模人口基礎、長達18年追蹤期（2003–2020年）、以及高度多重原發癌症患者的腫瘤登錄系統之一。相較於單一癌症部位的專科研究，全體癌症資料庫的系統性分析得以揭示癌症共病的橫向關聯結構，並藉此推測潛在的共同暴露因子與遺傳易感性。

本系列研究採用「由資料出發、逐層深化」的研究策略，分為四個遞進層次：

第一層：流行病學基礎建立——以古典統計方法（Cox比例風險模型、Kaplan-Meier分析、標準化發生比SIR）確立基礎臨床與流行病學事實。

第二層：深度學習潛在結構發現——以變分自動編碼器（VAE）、masked prediction Transformer、DeepHit競爭風險模型，從高維共病矩陣中抽取人類肉眼不可直接觀察的致癌暴露軸。

第三層：整合性驗證——以多元方法交叉驗證發現（SIR × 時變Cox × Transformer後驗機率），確保每項主要發現有獨立方法學的三角校驗。

第四層：臨床轉化——將研究發現轉化為可操作的監測建議、遺傳諮詢轉介標準，及資料驅動的診療優化工具。

台灣癌症登錄資料庫的整體探索性分析（n=84,161；2003–2020年）確立了以下基礎事實：

- 高死亡率部位 (>70%)：C15食道 (77%)、C22肝 (76%)、C13下咽 (73%)、C34肺 (72%)
- 低死亡率部位 (<25%)：C50乳腺 (22%)、C53子宮頸 (20%)、C54子宮體 (22%)
- 台灣特有性別極化：C15食道95%男性 (全球平均~75%)、C13下咽97%男性
- 多重原發規模：5%患者有≥2個癌症 (3,679人有2個, 389人有3個以上, 最多一人6個)

二、食道鱗狀細胞癌的臨床預後研究

2.1 全國資料庫分析 (C15子計畫)

C15子計畫以台灣癌症登錄資料庫中2,367名食道癌患者為隊列 (中位存活13.4個月; 1,832例死亡, 死亡率77.4%)，建立了迄今台灣最完整的食道癌多因子Cox預後模型。隊列特徵：鱗狀細胞癌85.4%、男性94.5%、中位年齡57歲、分期遺漏609人 (25.7%)。

主要發現：

變數	HR	95% CI	p
R0切除邊緣	0.63	0.55 – 0.73	<0.001
根治性食道切除	0.61	0.51 – 0.72	<0.001
內視鏡切除術	0.48	0.38 – 0.60	<0.001
Stage III vs I	1.23	1.07 – 1.41	0.003
Stage IV vs I (MICE主要)	1.63	1.42 – 1.87	<0.001
Stage IV vs I (7th edition-only)	2.17	1.78 – 2.64	<0.001
CCRT (MICE主要模型)	0.97	0.86 – 1.09	0.569 NS
C-index (apparent)	0.670	—	—
C-index (OOB B=500)	0.666	0.647 – 0.683	—

AJCC版本敏感性：台灣癌症登錄混用6th/7th edition, 6th edition將頸部淋巴結轉移 (M1a) 歸為Stage IV, 7th則重新分類為Stage III, 導致6th版Stage IV盛行率45.0% vs 7th版24.9%。7th edition-only分析 (n=1,187) 顯示Stage IV HR=2.17, 高於混用時的1.63, 反映6th版M1a稀釋效應。

CCRT時間依賴效應：三個模型設定的CCRT HR出現>25%的分歧 (MICE HR=0.97 NS; 完整病例敏感性HR=0.72; Zero-coded HR=0.76), Schoenfeld殘差 ($\chi^2=17.1$, $p<0.001$) 確認CCRT效應具有時間依賴性。二時段Cox (landmark=12個月) 揭示：早期 (<12個月) HR=0.846 (保護性, 反映局部控制效益), 晚期 (>12個月) HR=1.221 (效益抵銷或反轉, 與CCRT晚期毒性一致)。全時間段HR=0.97在數學上正確但生物學上無意義, 無法代表整體CCRT效應。

深度學習補充分析：自動編碼器→UMAP→k-means (k=3) 識別三個表現型群體, 但增量Cox檢定 $\Delta C = -0.001$ ($p>0.37$), 確認在此規模下深度學習無法優於傳統臨床分期。

MICE方法論：採用IterativeImputer+ExtraTreesRegressor處理25.7%分期遺漏，10次迭代，seed=42，提供了台灣食道癌研究中最具方法學嚴謹性的遺漏值處理框架。

2.2 中山醫大單中心驗證（CMUH ESCC）

CMUH食道癌資料庫（n=344；2007 – 2010年；AJCC 6th edition；93.9%男性；93.9%鱗狀細胞癌）提供了第一個與C15全國資料庫進行直接標竿比較的單中心驗證集。

標竿比較：

指標	C15全國（n=2,367）	CMUH（n=344）	判定
男性比例	94.5%	93.9%	✓ 一致
分期遺漏率	25.7%	27.0%	✓ 一致
R0率（手術者）	~87%	87.9%	✓ 一致
Cox C-index	0.670	0.691	✓ 一致
中位OS	13.4個月	9.6個月	⚠ 轉介中心效應
HR手術	0.61	0.41	△ 未調整分歧

深度學習四方法比較：

方法	C-index	主要發現
DeepSurv	0.691±0.059	n=334時無增益
XGBoost-Cox	0.667±0.048	SHAP解釋：年齡為最強非線性驅動因子
自動編碼器k=5	—	5個表現型，log-rank p<0.001
遷移學習（C15→CMUH）	0.599±0.086	時代+病例組合不相容，遷移失敗

遷移失敗根本原因：CMUH為2007 – 2010年轉介中心（中位OS 9.6個月） vs C15為2007 – 2020年全國資料庫（中位OS 13.4個月），時代與個案組合差異超出遷移可接受範圍。若CMUH資料可擴展至2015年後，預期遷移表現可改善。

三、上消化呼吸道場域致癌效應

UADT場域致癌（field cancerization）是指同一黏膜暴露場域內多個解剖部位共享致突變損傷的現象。在台灣，檳榔、菸草、酒精的三重暴露使此效應尤為突出。本子計畫以10個UADT部位（C02、C03、C04、C05、C06、C09、C10、C12、C13、C15）、10,113名患者（多場域1,067人，10.5%；三場域144人），建立了台灣UADT共病的全面流行病學圖像。

共發生率（最強配對）：

- C12梨狀竇 + C15食道：24.2%（每四名梨狀竇癌患者中即有一名發生食道癌，Rank 1）
- C13下咽 + C15食道：16.4%（Rank 2）

- 兩者均達BH校正FDR顯著

SIR分析（內部對照，288,424人年，Poisson精確CI）：

序列	SIR	95% CI
食道→下咽	4.7	3.1 – 6.7
梨狀竇→食道	3.8	2.4 – 5.7
食道→梨狀竇	3.6	1.9 – 6.3

方向對稱性：C13↔C15配對對稱指數=0.879（ $p=0.70$ ，非顯著）；60%在6個月內為同步性（SYNC_MO=6），敏感性分析（SYNC_MO=3：56%；SYNC_MO=9：63%）結果穩健。此結果支持共同暴露（場域效應）而非腫瘤擴散（克隆播散）的機制。

不死時間偏差修正：地標Cox（6個月）因殘餘不死時間偏差顯示HR=0.86（保護性假象），時變Cox（暴露時間從第二診斷日精確計算）顯示HR=2.14（95%CI 1.97 – 2.33， $p<0.0001$ ）。HR從0.86反轉為2.14是文獻中記載最清晰的不死時間偏差示範之一，確認多場域發癌是獨立的不良預後因子。

DeepHit競爭風險（UADT隊列）：5yr死亡CIF=56.7%，5yr第二UADT癌症CIF=10.4%。死亡在所有時間點均主導（C-td death=0.595）。臨床意涵：大多數UADT患者無法存活至晚期監測受益，因此監測應集中於確診後1 – 2年的早期窗口。

臨床意涵：梨狀竇癌患者的常規食道鏡監測具有充分的流行病學支撐（24.2%共發生率，SIR=3.8）。

四、共存癌症模式的資料驅動發現

以完整78,621名患者×46癌症部位的多熱編碼矩陣，本子計畫識別出三個主要共病生物學域：

域1：上消化呼吸道SCC場域（97%男性，中位診斷年齡53歲，17%發生第三個癌症）

- 下咽↔食道：lift=5.50，OR=6.77，n=156（最強共發生訊號）
- 口腔對：lift 4 – 6（檳榔場域致癌）
- 29個男性特異 vs 5個女性特異的高lift配對

域2：女性生殖道+乳腺（95%女性，年齡56歲）

- 子宮頸/子宮體/卵巢/乳腺的荷爾蒙/遺傳易感性共病網路

域3：年齡相關腸胃道/泌尿道

- C34+C50（n=132）、C18+C22（n=113）、C61+C67（n=105）
- 反映老化相關的代謝與免疫監控失能

NMF k=7程式（多重原發子隊列n=4,068，在全隊列進行NMF因單癌患者94.8%而退化）：

- P2「Aerodigestive SCC」：n=615，97%男性，年齡53，17%發生第三個癌症
- P5「口腔場域」：n=758，95%男性，年齡52，19%發生第三個癌症，3年間距
- P6「女性生殖/乳腺」：n=730，95%女性，年齡56
- P7「泌尿道」：n=406，90%男性，年齡72

SIR+疾病軌跡分析（Jensen 2014式）：

- 最強SIR：食道→下咽SIR=12.2，食道→梨狀竇SIR=12.0
- 雙向+同步（UADT配對）：下咽↔食道60%在6個月內，方向p=0.70
- 單向+延遲（乳腺→肺，n=97）：影像監測偵測型模式
- 69/179個配對FDR<0.05（總體288,424人年）

五、深度學習潛在空間與三軸癌症分類

5.1 變分自動編碼器（VAE）的低維潛在結構

以78,442名患者×37個部位的共病矩陣訓練VAE（12個潛在維度），僅3個維度呈現KL活躍（KL>0.1），代表台灣整體癌症共病空間由三個主要致癌過程主宰：

維度	生物學識別	性別偏向	年齡相關	時代趨勢
z4	UADT/場域致癌	男性（RBI=0.62）	$\rho = -0.23$ （年輕）	$\rho = +0.003$ （穩定）
z0	荷爾蒙/婦科	女性（RBI= - 0.16）	$\rho = +0.11$ （年長）	$\rho = +0.11$ （上升）
z5	荷爾蒙/婦科（第二）	女性（RBI= - 0.41）	$\rho = +0.33$ （年長）	$\rho = +0.07$ （上升）

z4的時代穩定性反映台灣UADT致癌暴露（主要為檳榔）在2003 – 2020年間維持不變；z0/z5的上升反映婦科癌症（尤其子宮體癌）的逐漸增加，可能與代謝症候群盛行率上升有關。

5.2 五群體分類與PH假設的重大修正

KMeans k=5群體的全時間段Cox模型中，Cluster 3的HR=44（95%CI 12.8 – 151）曾為最引人注目的發現。Schoenfeld殘差檢定（ $\chi^2=177.6$, p=10⁻⁴）確認此為PH假設的根本性違反：C3患者以胃癌（C16）為主，中短期死亡率高；存活至晚期者則以子宮體癌（C54）為主，死亡率低。強迫單一比例風險模型描述此混合模式，導致數值極端膨脹。

二時段Cox（landmark=2年）的正確結果：

- C3 HR=0.935（早期，p=0.004）
- C3 HR=0.870（晚期，p≈0）

C3實際上是比參照群體C2更低的死亡風險群體；HR=44是方法學假象，而非真實的生物學風險。此結論擴及整個模型：5項共變數中5項違反PH假設（C1 $\chi^2=317.7$ ，C4 $\chi^2=1093.7$ ，年齡 $\chi^2=273.3$ ，性別 $\chi^2=119.7$ ），全時間段Cox結果均須以二時段模型替代。

5.3 群體生物學標籤（待完成）

- C0（n=17,449，死亡率21%）：荷爾蒙/婦科主導
- C1（n=13,089，死亡率63%）：C34肺/C61攝護腺/C71腦/C22肝——可能為放射線誘發或HBV/代謝
- C2（n=25,174，死亡率51%）：C20直腸/C77淋巴結——可能為轉移富集
- C3（n=10,576，死亡率48%）：C54子宮體/C56卵巢/C16胃——混合GI/婦科

- C4 (n=12,154, 死亡率77%)：待標記（最高死亡率）

六、序列感知癌症監測日曆

6.1 Cancer-BERT Transformer

以2層/4頭/d=64的BERT架構（參數量76k）進行leave-one-out masked訓練（4,052名多重癌症患者，8,538訓練樣本），在雙向重建任務（bidirectional）中達到：R@1=0.312（2.4×MLP基準），R@3=0.562，R@5=0.711。

6.2 監測日曆（Script 12）

採用臨床現實情境查詢：[CLS, 首發癌症, MASK]，僅使用首發診斷，模擬臨床一線醫師在首診時的預測場景。

指標	數值	說明
R@1	0.232	8.6×隨機基準（1/37）
R@3	0.498	前三名涵蓋約半數真實後繼癌症
R@5	0.664	前五名涵蓋三分之二患者
中位癌間距	789天（2.2年）	IQR 461 – 1,175天
C12/C13→C15在6個月內	74%	與6個月食道鏡監測指引（Muto 2004）吻合
校準配對數	519個部位配對	涵蓋訓練集中的時序分佈Q1/中位數/Q3

6.3 多病史擴展的負面發現與BERT限制

以k=2（兩個癌症歷史）作為預測背景時，R@1=0.205（低於k=1的0.232），呈現「更多歷史反而更差」的悖論。根本原因：BERT雙向訓練架構對因果預測任務（以過去預測未來）存在根本性訓練/推論不匹配。模型在訓練時同時看到所有癌症（包括未來的），推論時僅有過去可用，導致模型退化為預測最常見的後繼癌症（C18大腸，約40%患者的Top-1預測）而喪失個人化預測能力。

下一步方向：以GPT式因果訓練（下三角注意力掩碼）重新訓練，預期R@1可恢復至0.15 – 0.25。

七、B型肝炎/腸胃道系統致癌軸

台灣成年人HBV血清陽性率歷史上高達15 – 20%（1986年前出生世代），構成台灣癌症分布的獨特背景。本子計畫以三角驗證方法論確認HBV/GI軸的獨立存在。

7.1 三角驗證

方法1：SIR分析

C22肝HCC作為第二原發癌症的SIR在所有指數部位均<<1（p<0.001）。此看似「陰性」的結果實為生物學預期：HBV感染者HCC傾向作為首個惡性腫瘤出現；一旦非肝臟首發癌出現，此患者的HBV易感池已被預先篩除，且HCC存活率低（5年約15%），存活下來發展順序型第二癌的機率極低。

方法2：共發生OR矩陣（多重原發子隊列）

- UADT部位對C22的共發生OR=0.11 – 0.35（強烈排斥）
- GI/系統部位對C22的OR=0.51 – 1.14（近中性，屬同軸共病）
- 兩軸在共病結構上完全不重疊

方法3：Transformer後驗機率

- P(C22∈top-3 | GI指數部位)=0.83
- P(C22∈top-3 | UADT指數部位)=0.09

7.2 兩個獨立非重疊致癌軸的確立

軸	部位	推測驅動因子	驗證來源
UADT/場域軸	C12↔C13↔C15、C06/C02	檳榔/菸草/酒精	SIR=2.86 – 4.67；TV-Cox HR=2.14；對稱=0.879
HBV/GI系統軸	C22+C18+C16+C34+C61+C67	HBV感染/NAFLD/代謝症候群	C22 ρ = – 0.983；OR矩陣；Transformer P=0.83

八、癌症發生率的時序趨勢分析

8.1 時序自相關修正方法（Chelton 1983）

傳統Spearman ρ 對18年時間序列（n=18個年度觀察值）的顯著性檢定，在AR(1)自相關係數φ ≥ 0.5時，有效自由度可從16降至僅約6，造成第一類錯誤膨脹。本研究引入有效樣本量修正法：

$$n_{\text{eff}} = n \cdot \frac{1 - \hat{\phi}^2}{1 + \hat{\phi}^2}, \quad t^* = \rho \cdot \sqrt{\frac{n_{\text{eff}} - 2}{1 - \rho^2}}$$

修正後，26個原本達naive顯著的部位趨勢降至19個——7個部位被識別為自相關假象。三項預先登錄假設因ρ值足夠大（|ρ|=0.773 – 0.983），在修正後仍維持顯著。

8.2 三項預先登錄假設的驗證

假設	部位	ρ	修正後p	結論
H1：C22因HBV疫苗下降	C22肝	– 0.983	<0.001	確認
H2：UADT因檳榔防制下降	C13下咽	– 0.773	<0.001	確認
H2b：C12梨狀竇同步下降	C12	+0.562	0.015	拒絕——反而上升

假設	部位	ρ	修正後p	結論
H3：荷爾蒙/代謝相關上升	C54子宮體	+0.925	<0.001	確認

額外顯著趨勢：C53子宮頸 $\rho = -0.946$ （HPV意識/疫苗效益）；C61攝護腺 $\rho = +0.895$ （PSA篩檢時代發現偏差）。

C12悖論：緊鄰的C12梨狀竇（上升）與C13下咽（下降）呈現反向趨勢，可能機制包括：梨狀竇因食道鏡監測普及被順帶偵測（監測偏差），或存在時間依賴的解剖編碼重分類。此發現需要臨床子研究釐清。

HBV疫苗效應的跨出生世代驗證：所有出生世代均呈現C22下降，1970年代後出生者 $\rho = -0.907$ （預計受益最大的疫苗接種世代），支持HBV疫苗接種為主要機制的假說。

九、遺傳症候群候選患者的資料驅動篩查

以自動編碼器識別的前1%異常患者（n=784，100%為多重癌症患者）進行Li-Fraumeni症候群（LFS）與Cowden症候群的表現型比對，完成台灣首次基於人口基礎腫瘤登錄的遺傳症候群非指定篩查。

Cowden症候群篩查結果：

篩查階段	候選數	篩選標準
自動編碼器anomaly screen	17	C50+C54, match_score $\geq$ 0.4
高信心精確化	3	match_score=1.0（同時具有C50及C54）

三名高信心候選（均為女性，具有乳腺C50+子宮體C54）：

- 年齡46歲：存活；另有C34肺
- 年齡49歲：死亡；另有C42血液
- 年齡57歲：存活；另有C53子宮頸

診斷年齡46/49/57歲與Cowden症候群乳腺/子宮體發病年齡範圍（文獻38 – 55歲）高度吻合。建議對三名患者進行PTEN種系基因檢測轉介。

LFS篩查失敗分析：26名候選患者在精確化後全數排除，主因台灣癌症登錄缺乏C49（軟組織肉瘤）與C74（腎上腺皮質癌）部位碼，LFS有效可辨識特徵場縮至{C50, C71}（match_score=0.5），特異性不足以區分LFS與一般乳腺多發性癌症。

登錄覆蓋率差距：C49（軟組織肉瘤）、C73（甲狀腺）、C74（腎上腺）的缺失是台灣癌症登錄遺傳症候群篩查的根本限制，需與登錄資料庫維護單位協調。

十、性別特異性癌症圖譜

針對37個癌症部位的全面性別分佈分析（費雪精確檢定+BH FDR校正），識別16個男性主導部位、4個女性主導部位（C50/C53/C54/C56）、17個性別中性部位。

主要量化結果：

指標	數值
最強男性主導：C12梨狀竇	OR=40×
最強女性主導：C50乳腺	OR=0.002×（99.8%女性）
UADT男性比女性早診斷	5–9年（C02/C06/C15）
多重癌症率 男性 vs 女性	6.8% vs 3.4%（2.0×
UADT子群 多重癌症率	14.9% vs 7.7%（1.9×
排除UADT後的超額男性多重癌症率	6.0% vs 2.1%（2.9×
VAE z4 UADT軸性別偏向	RBI=−0.621（男性）
VAE z5 荷爾蒙軸性別偏向	RBI=+0.409（女性）

兩個正交性別軸：

- 男性軸：檳榔/菸草UADT（z4）+ HBV/代謝GI；UADT男性比女性早5–9年確診，反映更早的致癌物暴露起始年齡
- 女性軸：荷爾蒙/婦科（z0/z5）；C50乳腺OR=0.002，C53/C54/C56實質上為女性排他性

男性非UADT多重癌症超額之謎：排除UADT後，男性多重癌症率仍為女性的2.9倍，提示可能存在男性免疫監控效能較低、荷爾蒙相關DNA修復差異，或致癌物交叉效應等尚未釐清的機制，是重要的未來研究方向。

十一、TCGA多體學分析

11.1 TCGA-THCA：乳突型甲狀腺癌的ECM重塑特徵

隊列：n=499 PTC（TCGA-THCA）；RNA-seq（60,660基因）、WXS/MAF（498例）、臨床（507例）；PFI端點（50個事件；EPV=10）。

ECM重塑特徵：

- 進展期 vs 早期DEGs：241個，ASPN、POSTN、COL1A1、ADAM12上調；PVALB、CASR、SFRP1下調
- GSEA最強NES：膠原纖維組織（NES=2.94）、ECM分解（NES=2.80）
- ESTIMATE間質評分在進展期顯著升高（ $p<0.001$ ）

BRAF V600E：

- 主要驅動突變（61.1%），與RAS互斥
- BRAF+有3,062個DEGs，含TGFBRI上調及T細胞途徑富集（NES 2.29–2.43）
- RF BRAF預測OOB AUC=0.935（從Top-50 DEG表達）

- Cox模型中BRAF非獨立預後因子 ($p>0.05$)

Cox存活預測 (Model B, $n=496$, 50個事件) :

預測因子	HR	95% CI	p
T3 – T4分期	2.36	1.28 – 4.33	0.006
年齡 ≥ 55 歲	1.96	1.11 – 3.46	0.021
N1、BRAF+, Follicular Variant	NS	—	>0.05

Schoenfeld全域 $p=0.41$ (所有5項共變數通過PH假設, p 範圍0.23 – 0.97) , Bootstrap B=200校正後C-index=0.677 (apparent C=0.689, optimism=0.012) 。

GSEA 500排列數 (修正前使用100排列) : BRAF顯著路徑數1,684 $\rightarrow$ 1,632 (修正後) , 確保 p 值計算精確度 (最小可達 $p=1/500=0.002$) 。

11.2 TCGA-BRCA：乳癌VAE表現型分析

隊列： $n=1,072$ (RNA-seq 60,660基因 $\times$ 1,095樣本) ; VAE最佳 $k=7$ (log-rank $p=0.018$) ; PAM50 ARI=0.301/NMI=0.449。

Basal的異質性 (核心發現) :

- C5 ($n=62$, 中位OS 614天) : 預後差Basal
- C6 ($n=130$, 中位OS 1,093天) : 預後較好Basal
- 兩組差距1.8倍; 兩組在常規PAM50分類下均為「Basal」

HOXB基因特徵: SHAP識別HOXB5 (rank

1) 、HOXB6、HOXB3、HOXB4為最主要表現型驅動基因 (C6 $>$ C5) 。外部驗證:

- METABRIC : HOXB4 FDR=0.0007 (所有HOXB基因 $p<0.001$)
- GSE96058 (SCAN-B) : 所有HOXB基因 $p<0.001$

預後預測: XGBoost-Cox C-index=0.727 (最高) , 但相對PAM50+分期的增量 $\Delta C=+0.005$, 未達實質臨床增量, 顯示現有DL模型在乳癌預後預測上尚未超越已知分子分類系統。

11.3 TCGA-ESCA：TP53突變的免疫微環境分析

隊列: 143名通過CIBERSORT QC篩選 ($nu=0.5$; $p<0.05$ permutation) 的TCGA食道癌患者 (突變=122, 野生型=21) 。

M2巨噬細胞增加 (FDR=0.045) : TP53突變患者M2巨噬細胞浸潤顯著升高 (零值膨脹特性: 58%突變型非零 vs 24%野生型) , 與TP53介導的免疫抑制性腫瘤微環境重塑機制一致。

CD8+ T細胞: 生物學零假設確認:

- 10種去卷積方法最佳 $p=0.189$ (Wilcoxon) , FDR=0.515
- CD8A/CD8B基因表達差異: $p=0.298$ (非顯著)
- Cohen's d=0.234 (小效應量)
- 達80%功效所需 $n_{wt}=194$ (現有 $n_{wt}=21$; 差距9.2倍)

- 根本原因：ESCC中TP53突變率幾乎100%，「突變 vs 野生型」的比較在ESCC中生物學上缺乏足夠對照組

十二、方法學創新與系統性貢獻

本系列研究在方法學上作出以下系統性貢獻，超越個別子計畫的具體發現：

12.1 比例風險假設的系統性驗證

所有Cox模型均執行Schoenfeld殘差檢定（Python: lifelines.proportional_hazard_test；R: cox.zph）。三個子計畫發現重要的PH違反：

子計畫	違反變數	χ^2	結果修正
三軸分類	C3、C1、C4、年齡、性別	177.6 – 1093.7	全時間段Cox替換為二時段模型
C15食道癌	CCRT、Margin R0、Stage IV	8.1 – 17.1	早期/晚期分段HR代替單一HR
TCGA-THCA	全部通過	全域p=0.41	確認模型有效性

12.2 不死時間偏差的時變Cox修正

UADT場域存活分析中，地標Cox（HR=0.86，保護性假象）vs 時變Cox（HR=2.14，真實效應）的4.8倍反轉，對任何使用多重原發事件作為暴露定義的存活分析提供關鍵的方法學警示。

12.3 時序自相關修正

Chelton（1983）有效樣本量法將26項naive顯著趨勢修正為19項，確保趨勢分析結論的統計有效性。三項預先登錄假設因效應量足夠大（ $|\rho|=0.773-0.983$ ），在修正後仍穩健顯著。

12.4 BERT訓練/推論一致性的定量評估

多病史分析量化了BERT雙向訓練對因果推論任務的架構不匹配效應：Script 25三個累積程式錯誤（架構不匹配+年齡正規化錯誤+去重複化缺失）造成R@1從0.232人為降至0.067（3.5倍假象下降），是醫學AI系統架構選擇的重要警示案例。修正全部錯誤後，R@1=0.232的監測日曆準確度確認有效。

十三、整合性結論與研究展望

13.1 台灣癌症流行病學的三軸統一敘述

基於本系列研究的全景視角，台灣癌症流行病學可以以三個互補且非重疊的致癌軸加以統一描述：

第一軸：UADT場域致癌軸（男性，穩定，台灣特有）

- 由台灣特有的檳榔/菸草/酒精三重暴露驅動

- 95 – 97%男性，中位診斷年齡53歲（比台灣平均年輕）
- 2003 – 2020年在VAE潛在空間中保持時代穩定（ $\rho \approx 0$ ）
- 跨方法三角驗證：SIR=3.8 – 4.7、TV-Cox HR=2.14、Transformer P(C15|C12)=0.12

第二軸：HBV/GI代謝軸（跨性別，持續下降）

- 由歷史性HBV高盛行率驅動，受惠於1986年起的疫苗接種政策
- C22肝HCC發生率 $\rho = -0.983$ （下降）持續跨越所有出生世代
- 長期監測可量化HBV疫苗的人口級抗癌效益

第三軸：荷爾蒙/婦科軸（女性，持續上升）

- 以子宮體癌（C54， $\rho = +0.925$ ）的快速上升為代表
- 與代謝症候群和女性生活型態改變相關
- 是未來人口老化最重要的預期負擔增長來源

13.2 臨床轉化的優先事項

最高優先（立即可行）：

1. 梨狀竇癌患者的常規食道鏡監測——24.2%共發生率與SIR=3.8提供充分的流行病學依據；監測時間窗（74%在6個月內）已被資料驗證，符合現行指引（Muto 2004, Huang 2015）。
2. PTEN種系基因檢測轉介——3名Cowden症候群高信心候選患者（C50+C54，年齡46/49/57歲）應接受遺傳諮詢。

高優先（待研究啟動）：

3. 監測日曆的電子病歷整合——以 $R@1=0.232$ 的Transformer監測日曆為核心，建立首發診斷時自動觸發的後續癌症風險評估工具，UADT患者群體為首要目標。
4. 全面C50+C54 Cowden篩查——對全部多重原發癌症患者（不限前1%異常患者）執行match_score=1.0篩選，擴大高信心候選識別。

中優先（需資料或基礎設施）：

5. 因果Transformer重訓練——GPT式下三角注意力掩碼重訓練，預期多病史推論 $R@1$ 可恢復至0.15 – 0.25。
6. HBV血清學臨床子隊列整合——以解決登錄資料中HBV狀態缺失的根本限制。
7. 登錄覆蓋率補充——C49/C73/C74的納入，以實現完整的遺傳症候群篩查。

13.3 研究限制的系統性彙整

資料層面：

- 無個人基因組/體細胞突變資料，無法識別分子亞型
- 無治療記錄，存活模型受治療混淆
- 無檳榔/菸草個人暴露量，僅能進行生態層次的暴露推論
- 無HBV血清學狀態

統計層面：

- EPV（事件數/預測因子數）：THCA EPV=10，屬假說生成層次

- 遺傳症候群篩查n=3, 缺乏背景盛行率分母（無效假設模型）
- 多重癌症率的時序下降分析受限於追蹤時間不均一（較晚診斷者追蹤較短）

驗證層面：

- 所有深度學習發現均為回顧性；R@1=0.232需前瞻性內視鏡產出作為終點的獨立驗證
- Basal乳癌HOXB分層的臨床實用性需在前瞻性隊列中驗證
- Cowden候選患者為個案層次，需群體層次的PTEN突變率估算

資料可及性

所有分析程式碼公開於：

- github.com/jnynlin/taiwan-cancer-registry（台灣癌症登錄系列）
- github.com/jnynlin/tcga-brca（TCGA-BRCA）
- github.com/jnynlin/tcga-thca（TCGA-THCA）

患者層級資料受隱私保護而不公開。統計摘要輸出可應要求提供。台灣癌症登錄資料依 [機構名稱] IRB [編號] 審查通過。TCGA資料依GDC資料使用政策取得，無需額外IRB審查。

致謝

作者：\[AUTHOR 1\]¹, \[AUTHOR 2\]², \[CORRESPONDING AUTHOR\]¹

機構：¹ \[Institution 1\], ² \[Institution 2\]

通訊作者：\[email@institution.edu.tw\]

倫理聲明：IRB \[編號\]

資助聲明：\[待填\]

利益衝突：無

本總論版本：2026-06-06。涵蓋17個子計畫之核心發現，包含三項方法學修正（比例風險假設、不死時間偏差、時序自相關）及其對研究結論的影響說明。